ROADMAP HOÀN THIỆN PROJECT

Bước tiếp theo để hoàn thiện hệ thống và đưa vào ứng dụng thực tế

ACTION ROADMAP

Bước tiếp theo để hoàn thiện project và đưa vào ứng dụng thực tế

Roadmap chuyển từ MVP kỹ thuật sang một hệ thống có model thật, benchmark rõ ràng, pilot có consent và có khả năng ứng dụng trong công việc/cuộc sống mà không biến sentiment thành đánh giá con người.

Ưu tiên: bằng chứng -> dữ liệu -> model -> đo lường -> pilot -> production.

1. Mục tiêu đích

Project hiện đã có nền tảng tốt ở tầng pipeline và kiến trúc. Bước tiếp theo không phải thêm thật nhiều công nghệ, mà là **biến hệ thống từ "có thể phân tích" thành "được chứng minh là phân tích hữu ích và vận hành an toàn"**.

Đích 1 - cho luận văn: có evidence thật, số liệu thật và câu trả lời rõ cho từng Research Question.

Đích 2 - cho sản phẩm: model thật + dữ liệu đúng miền + dashboard có giá trị sử dụng + security/consent đủ để pilot với người thật.

2. Thứ tự ưu tiên đúng

1. **P0 - Evidence và kết quả MVP:** hoàn thiện bằng chứng trước, vì nếu không có evidence thì claim kiến trúc vẫn chỉ là mô tả.
2. **P1 - Dataset và annotation:** cần ground truth trước khi đánh giá model.
3. **P2 - Classifier thật:** benchmark model để biến rule demo thành NLP system có bằng chứng.
4. **P3 - Performance/resilience:** đo latency, throughput và recovery trước khi gọi là near-real-time.
5. **P4 - Pilot có consent:** kiểm tra giá trị sử dụng và cách người dùng hiểu output.
6. **P5 - Production hardening:** auth, TLS, retention, audit và monitoring sau khi use case đã chứng minh giá trị.

3. Phase 0 - Chốt luận văn và evidence

Phase 0: Freeze phiên bản có thể bảo vệ 1-3 ngày

- Chạy lại `pytest`, smoke pipeline, `verify.sh`, `runtime-status.sh`.
- Tạo Evidence ID cho từng run.
- Lưu commit hash, OS, CPU/RAM, Docker/Compose version, command, exit code và stdout đã redaction.
- Chụp dashboard và API response cho một meeting fixture.
- Tạo bảng "Evidence summary" trong Chương 8: số run, pass/fail, Evidence ID.
- Trong Chương 10, trả lời từng Research Question: Supported / Partially supported / Not yet evaluated.

Điều kiện hoàn thành: bất kỳ câu "đã kiểm chứng" nào trong luận văn đều trỏ được tới một Evidence ID cụ thể.

4. Phase 1 - Tạo dataset đúng domain

Phase 1: Dataset và guideline 1-2 tuần cho pilot nhỏ

1. Chọn use case cụ thể: họp nhóm nội bộ, phỏng vấn nghiên cứu, chăm sóc khách hàng, lớp học/nhóm học tập...
2. Tạo guideline 3 lớp: positive / neutral / negative và quy tắc unknown.
3. Định nghĩa cách xử lý phủ định, mỉa mai, câu trích dẫn, code-switch, câu quá ngắn.

4. Thu transcript có consent hoặc dữ liệu được phép sử dụng.
5. Gán nhãn bởi ít nhất 2 annotator độc lập.
6. Đo Cohen's kappa hoặc Krippendorff's alpha.
7. Split theo **meeting**, không split ngẫu nhiên theo segment.

Dataset pilot tối thiểu nên có:

- **20-30 meetings hoặc phiên hội thoại:** đủ để kiểm tra pipeline/label guideline và phát hiện lỗi thiết kế.
- **Khoảng 1.000-3.000 analysis units:** đủ cho baseline nhỏ và error analysis ban đầu; chưa nên coi là dataset production.
- **2 annotators:** dùng để đo độ nhất quán của nhãn.
- **Test set khóa:** không dùng khi tuning.

5. Phase 2 - Thêm model thật

Phase 2: Benchmark model 1-3 tuần

Không bắt đầu bằng mô hình phức tạp nhất. Hãy tạo một đường baseline -> model mạnh:

1. **Baseline ML:** TF-IDF + Logistic Regression.
2. **Model tiếng Việt:** PhoBERT fine-tune.
3. **Comparator:** XLM-R hoặc mBERT nếu dữ liệu có code-switch đáng kể.
4. Đưa ít nhất 2 model vào cùng `SentimentClassifier` adapter contract để chứng minh RQ2.

Metric bắt buộc:

- **Macro-F1:** không để lớp neutral lớn che lỗi positive/negative.
- **Precision / Recall / F1 từng lớp:** hiểu loại lỗi nào nguy hiểm.
- **Confusion matrix:** nhìn rõ nhầm lẫn giữa các lớp.
- **Prediction/effective coverage:** đánh giá mức dữ liệu thực sự được phân tích.
- **Calibration:** chỉ cần khi muốn diễn giải confidence như xác suất.
- **P50/P95 inference:** đánh giá khả năng dùng trong near-real-time.

6. Phase 3 - Sửa logic aggregate

Cần xử lý trước khi dùng score trong thực tế: nếu confidence chưa calibrated thì không nên dùng confidence như trọng số "độ đúng" trong aggregate. Tương tự, số token dài hơn không mặc nhiên có nghĩa phát ngôn quan trọng hơn.

Hãy benchmark ít nhất ba cách:

1. Unweighted label ratio.
2. Mean probability sau calibration.
3. Weighted score hiện tại.

So sánh stability và khả năng giải thích. Nếu score chỉ dùng visualization, ghi rõ là heuristic, không dùng như chỉ số đánh giá người nói.

7. Phase 4 - Đo performance và resilience

Phase 4: Performance engineering 3-7 ngày

- Đo end-to-end latency: capture/ingest/queue/analysis/delivery.
- Đo P50/P95/P99, throughput, queue lag, retry/failure rate.
- Test worker restart sau khi commit nhưng trước ACK.
- Test Valkey unavailable.
- Test duplicate/tampered/replayed webhook.
- Test transcript revision muộn sau prediction.
- Test dashboard SSE reconnect.

Điều kiện hoàn thành: bạn có thể định nghĩa "near-real-time" bằng số thay vì bằng cảm nhận.

8. Phase 5 - Pilot ứng dụng thực tế

Ứng dụng phù hợp nhất là những use case **phân tích nội dung cuộc hội thoại**, không phải chấm điểm cá nhân.

- **Team retrospective:** tìm đoạn trao đổi căng thẳng/tích cực để review; output là timeline + evidence, không phải đánh giá cá nhân.
- **Customer interview / user research:** xem phản ứng tích cực/tiêu cực theo topic hoặc tính năng; output theo topic/window.
- **Customer support QA:** ưu tiên đoạn hội thoại cần người quản lý xem lại; không tự động phạt nhân viên.
- **Lớp học / nhóm học tập:** quan sát đoạn thảo luận khó hiểu hoặc thiếu tương tác; không chấm điểm sinh viên.
- **Workshop / brainstorming:** xem thay đổi phản ứng theo ý tưởng/chủ đề/thời điểm.
- **Tự ghi chú cá nhân:** người dùng tự xem transcript của chính mình trong chế độ private; không suy luận sức khỏe tâm thần.

Use case nên chọn để pilot đầu tiên: "meeting retrospective / user research". Hai use case này dễ xin consent, ít rủi ro hơn HR scoring và có giá trị rõ: giúp người dùng tìm nhanh đoạn cần xem lại.

9. UX pilot tối thiểu

Cho 5-10 người dùng thử với một bộ transcript synthetic/redacted hoặc consented và yêu cầu họ:

1. Tìm một đoạn negative và mở evidence.
2. Nhận biết khi effective coverage thấp.
3. So sánh hai revision của cùng meeting.
4. Giải thích model version và confidence.
5. Trả lời câu: "Dashboard có cho phép kết luận người này tiêu cực không?" - câu đúng phải là **không**.

Đo task completion, thời gian hoàn thành, lỗi diễn giải; nếu cần có thể thêm SUS.

10. Phase 6 - Production hardening

Phase 6: Đưa pilot thành sản phẩm 2-8 tuần tùy phạm vi

- Authentication: OIDC/OAuth/JWT hoặc SSO.
- Authorization: workspace/role/tenant isolation.
- TLS reverse proxy và secret management.
- Consent lifecycle và retention/delete workflow.
- Audit log cho truy cập transcript/evidence.
- Backup + restore drill.
- Central logging/metrics/alerts.
- Model registry/MLflow chỉ thêm khi đã có nhiều artifact model và quy trình promotion thực sự.

11. Backlog 15 action cụ thể

1. Freeze Git commit dùng cho luận văn.
2. Chạy unit test và tạo Evidence ID.
3. Chạy smoke integration và tạo Evidence ID.
4. Chụp API/dashboard evidence đã redaction.
5. Thêm bảng trả lời RQ1-RQ4 vào Chương 10.
6. Chọn 1 use case pilot.
7. Viết annotation guideline.
8. Tạo 1.000+ analysis units pilot nếu dữ liệu cho phép.
9. Gán nhãn 2 người + đo agreement.
10. Train TF-IDF+LR.
11. Fine-tune PhoBERT.
12. Benchmark model và error analysis.
13. Tích hợp model tốt nhất qua adapter.
14. Đo latency/resilience.
15. Chạy UX pilot với người dùng thật có consent.

12. KPI để biết project đã "trưởng thành" hơn

Research
Có dataset version, agreement, Macro-F1, error analysis.

System
Có P95 latency, throughput, fault-recovery evidence.

Product
Người dùng hoàn thành task và hiểu đúng giới hạn output.

Governance
Consent, access control, retention và audit hoạt động.

13. Gợi ý lộ trình 30 ngày

- **Tuần 1:** Evidence + luận văn + dataset guideline. Deliverable: evidence bundle, bảng trả lời RQ, annotation guideline.
- **Tuần 2:** Dataset pilot + baseline ML. Deliverable: dataset v0.1, agreement, TF-IDF+LR metrics.
- **Tuần 3:** PhoBERT + adapter + benchmark. Deliverable: model artifact, model card, comparison table.
- **Tuần 4:** Performance + UX pilot. Deliverable: P95 latency, failure tests, 5-10 user sessions, roadmap production.

14. Việc không nên làm ngay

- Không vội chuyển sang Kubernetes/multi-region nếu chưa có workload thực.
- Không thêm GPU chỉ để "trông giống AI system".
- Không mở rộng Teams/Zoom/Jitsi trước khi Google Meet flow có evidence đủ mạnh.
- Không dùng sentiment để xếp hạng nhân sự hoặc suy luận sức khỏe tâm thần.
- Không tối ưu model trước khi guideline và dataset ổn định.

15. Action đầu tiên nên làm ngay ngày mai

Action #1: tạo một Evidence Bundle hoàn chỉnh cho một run integration PASS và cập nhật Chương 8/10 bằng Evidence ID đó.

Action #2: chọn đúng một use case pilot và viết annotation guideline 3 lớp cho use case đó.

Action #3: triển khai TF-IDF + Logistic Regression như classifier adapter thứ hai trước khi đi PhoBERT. Đây là cách nhanh nhất để chứng minh thiết kế "replaceable model" bằng dữ liệu thực tế.

Roadmap này là khuyến nghị kỹ thuật dựa trên trạng thái và giới hạn được chính khóa luận mô tả; các mốc thời gian là ước lượng thực hành, không phải kết quả đã được chứng minh trong tài liệu nguồn.