Hệ thống phân tích sắc thái cảm xúc từ transcript tiếng Việt trong họp trực tuyến

Kiến trúc MVP hạ tầng: Truy vết bằng chứng và bảo vệ quyền riêng tư

Báo cáo Khóa luận tốt nghiệp — Khoa Khoa học Máy tính

Gemini Notebook

DATA NOISE IN AUTOMATIC SPEECH RECOGNITION (ASR) & CORRECTION FRAMEWORK

Visualizing Raw Transcript Distortions and the Necessity of Quality Control Infrastructure

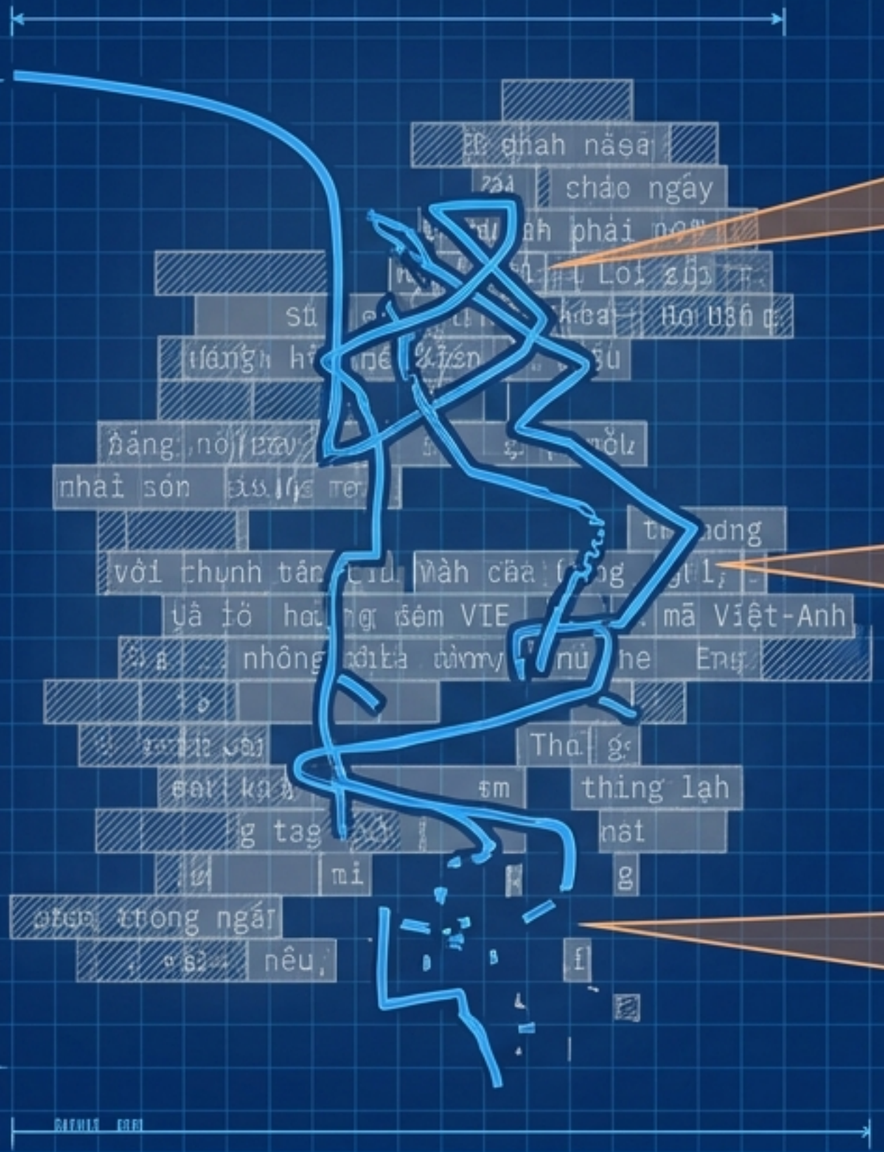

Overlap
(lời nói chồng lấn)

Code-switching
(chuyển mã Việt-Anh)

Short segments
(phát ngôn ngắn)

ASR DATA NATURE & AI IMPLICATIONS

- Bản chất của dữ liệu ASR là các quan sát có sai số, không phải ground truth ngôn ngữ.

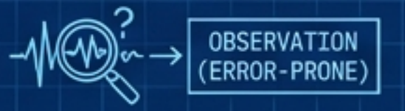

- Transcript sinh tự động thường xuyên gặp vấn đề về tiếng ồn nền, lỗi phân tách người nói (diarization), và hiện tượng chuyển mã.

- Việc áp dụng trực tiếp một mô hình AI lên luồng dữ liệu này mà không có cơ sở hạ tầng kiểm soát chất lượng sẽ dẫn đến các kết quả phân tích sai lệch và không thể truy vết.

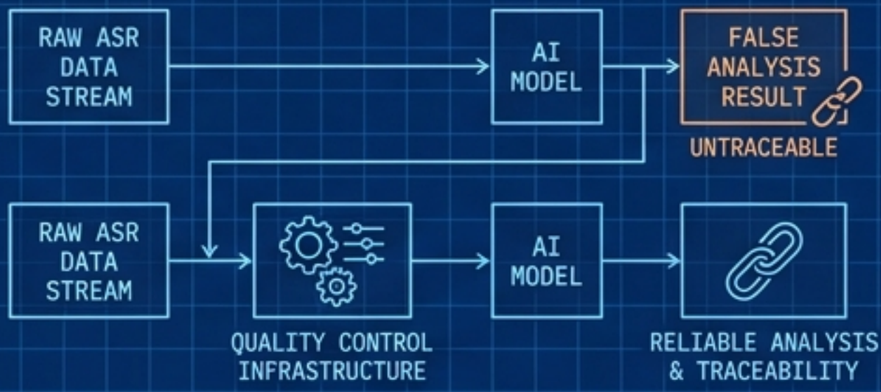

DWG NO. ASR-QC-001 | REV B | SCALE: NTS | DATE

Gemini Notebook

Ranh giới đạo đức: Hệ thống phân tích văn bản, không phải công cụ chẩn đoán.

Hệ thống của MVP (Trong phạm vi)

- Phân tích sắc thái văn bản (Text polarity: Positive, Neutral, Negative, Unknown).
- Giới hạn trong ngữ cảnh hẹp của một lượt thoại (Analysis Unit).
- Mục đích: Hỗ trợ người dùng quan sát xu hướng biểu đạt của nội dung trao đổi.

Chẩn đoán y tế lâm sàng (Ngoài phạm vi)

- Đánh giá trạng thái tâm lý hoặc cảm xúc con người (Emotion/Intent).
- Sử dụng công cụ đo lường lâm sàng (PHQ-9, DSM-5).
- Mục đích: Suy luận, chẩn đoán trầm cảm hoặc hỗ trợ quyết định nhân sự/học tập.

DWG NO. ASR-QC-001 | REV B | SCALE: NTS | DATE

Gemini Notebook

Mục tiêu DSR: Xây dựng Artefact phần mềm có thể truy vết và kiểm toán.

Block 1

Câu hỏi 1 (Lọc & Truy vết): Pipeline có loại bỏ, lưu vết vết lý do và bảo toàn revision của transcript không đủ điều kiện trước khi suy luận?

Block 2

Câu hỏi 2 (Giao diện Adapter): Hợp đồng có cho phép thay thế bộ phân loại (ví dụ: PhoBERT) mà không phá vỡ API, database và dashboard?

Block 3

Câu hỏi 3 (Kiến trúc Sự kiện): Luồng event-driven có đảm bảo hoàn tất ingest, phân tích và cập nhật UI từ segment cuối cùng một cách nhất quán?

Block 4

Câu hỏi 4 (Oversight UI): Evidence, confidence và coverage được trình bày như thế nào để ngăn chặn việc diễn giải quá mức kết quả AI?

Gemini Notebook

Phạm vi và Giới hạn: Xây dựng nền tảng, không phải benchmark mô hình.

Bên ngoài MVP (Hướng phát triển)

Bên trong MVP (Đã kiểm chứng)

Nguồn: Google Meet (thông qua Vexa bot).

Runtime: baseline-rules-v2 (Dùng để kiểm thử data contract, không đo accuracy).

Hạ tầng: Local Docker, PostgreSQL, Valkey Stream.

Mô hình: PhoBERT fine-tune, Custom ML models.

Nguồn: Microsoft Teams, Zoom, Jitsi.

Hạ tầng: Kubernetes, MLflow Registry, High Availability.

Gemini Notebook

Vòng đời dữ liệu: Từ điểm thu nhận âm thanh đến giao diện giám sát.

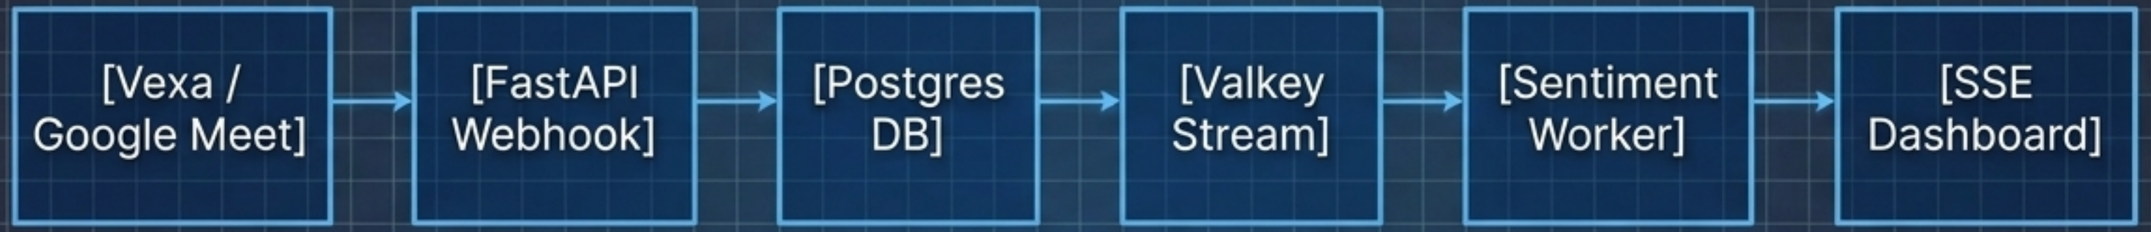

Kiến trúc tách bạch rõ ràng giữa nền tảng họp (Vexa), nguồn dữ liệu chuẩn của ứng dụng (PostgreSQL), và hàng đợi xử lý bất đồng bộ (Valkey).

Sự phân tách này cho phép hệ thống kiểm soát hoàn toàn phiên bản (revision) và bảo toàn lịch sử phân tích ngay cả khi transcript bị sửa đổi.

Gemini Notebook

Quality Gate và Language Routing: Bảo vệ đầu vào của mô hình.

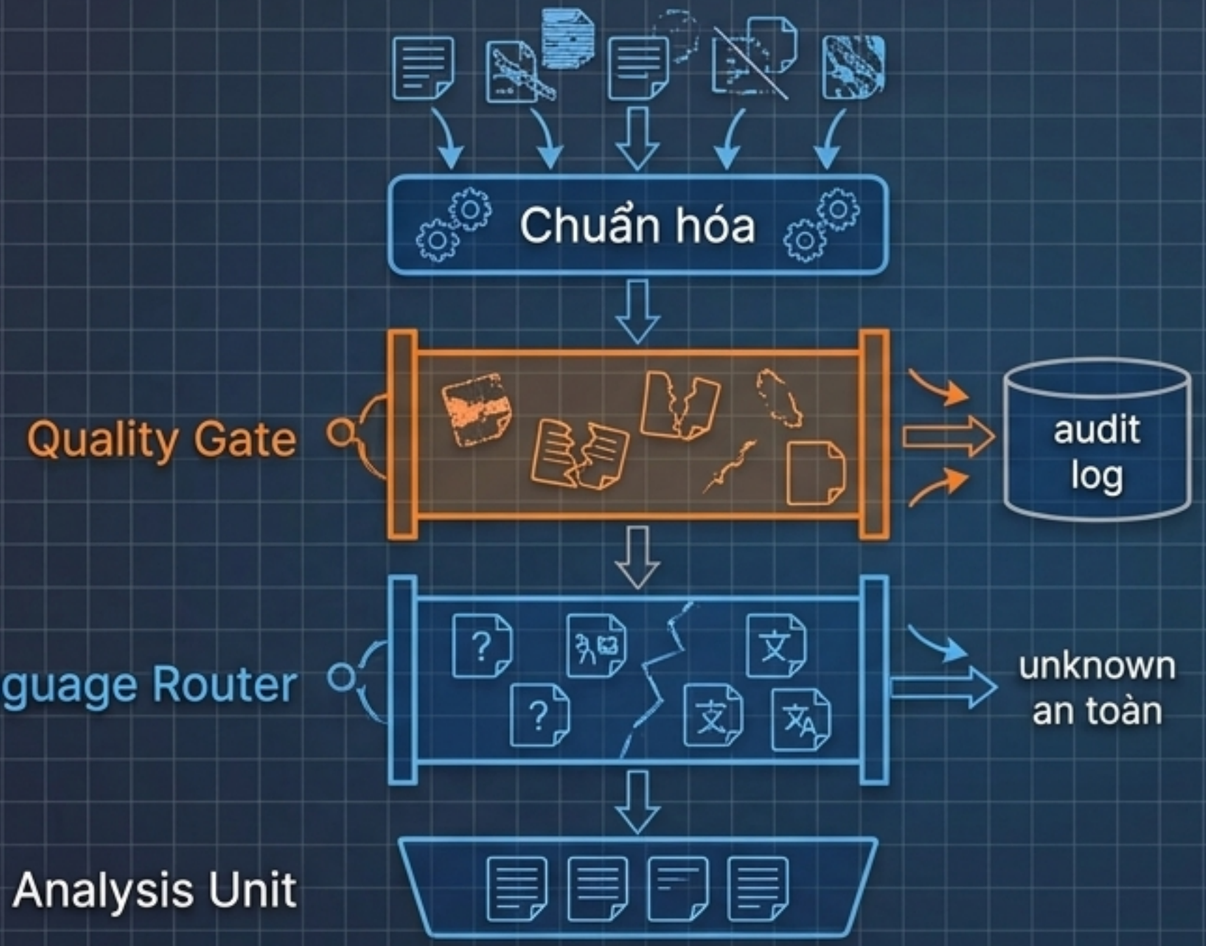

Dữ liệu được đưa về dạng Unicode NFC, giữ nguyên dấu tiếng Việt để không làm mất ngữ nghĩa.

Lọc bỏ segment rỗng, quá ngắn (<3 token), thời gian âm, chưa final, bị thu hồi (retracted), hoặc chứa mẫu hallucination. Lý do loại được lưu lại để audit.

Chỉ ưu tiên unit có dấu hiệu tiếng Việt. Các ngôn ngữ khác trả về trạng thái unknown an toàn.

Ghép tối đa 3 final segment liền kề của cùng speaker trong cửa sổ 45 giây.

Gemini Notebook

Các chỉ số Coverage: Định lượng mức độ tin cậy của dữ liệu phân tích.

Hệ thống không cho phép diễn giải nhầm tỷ lệ dự đoán 100% trên tập dữ liệu chỉ có 10% hợp lệ là một thành công.

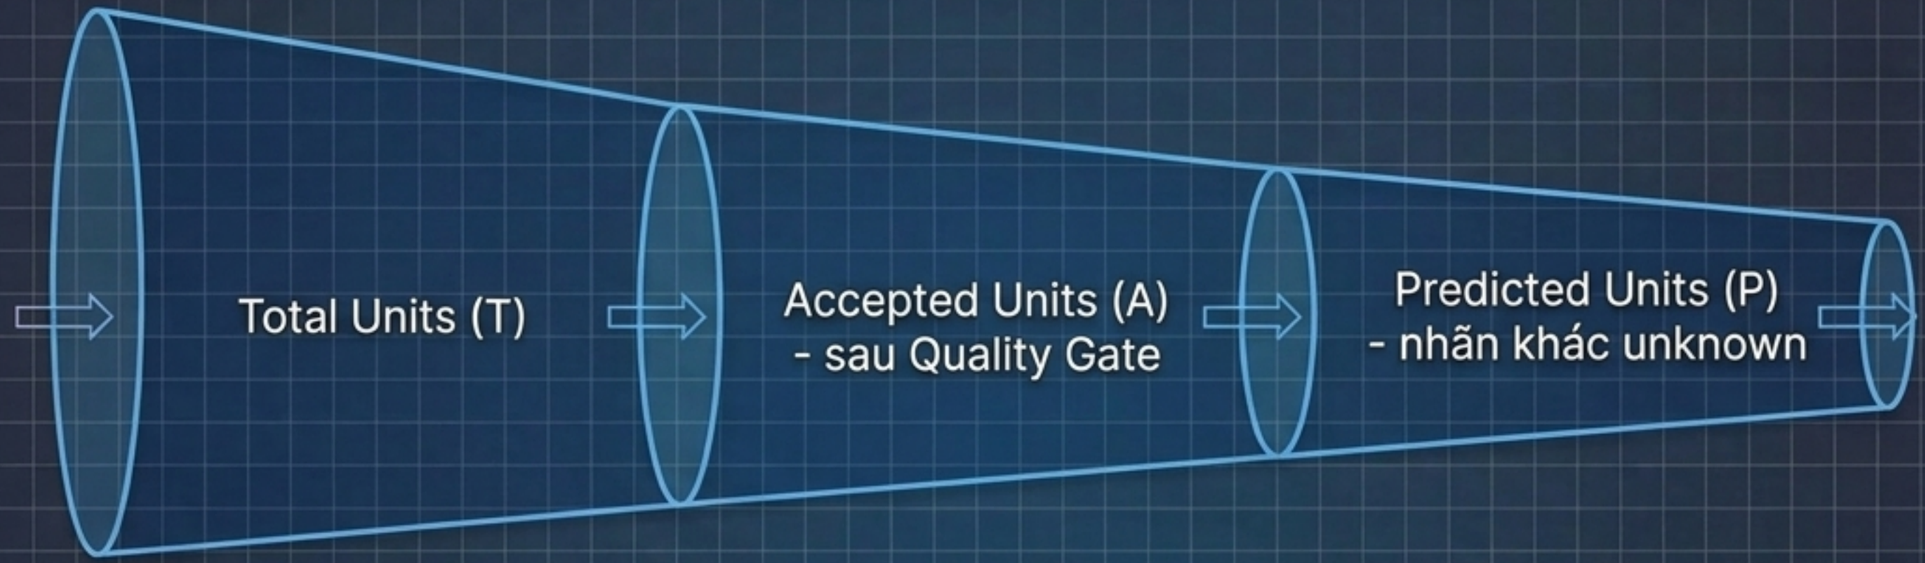

Acceptance Rate (A/T): Phản ánh chất lượng của đầu vào ASR.

Prediction Coverage (P/A): Phản ánh năng lực xử lý của mô hình và routing.

Effective Coverage (P/T): Chỉ số cốt lõi cho biết bao nhiêu phần trăm nội dung ban đầu thực sự nhận được dự đoán cảm xúc.

Gemini Notebook

Hợp đồng Adapter: Tách rời thuật toán khỏi cơ sở hạ tầng (MLOps).

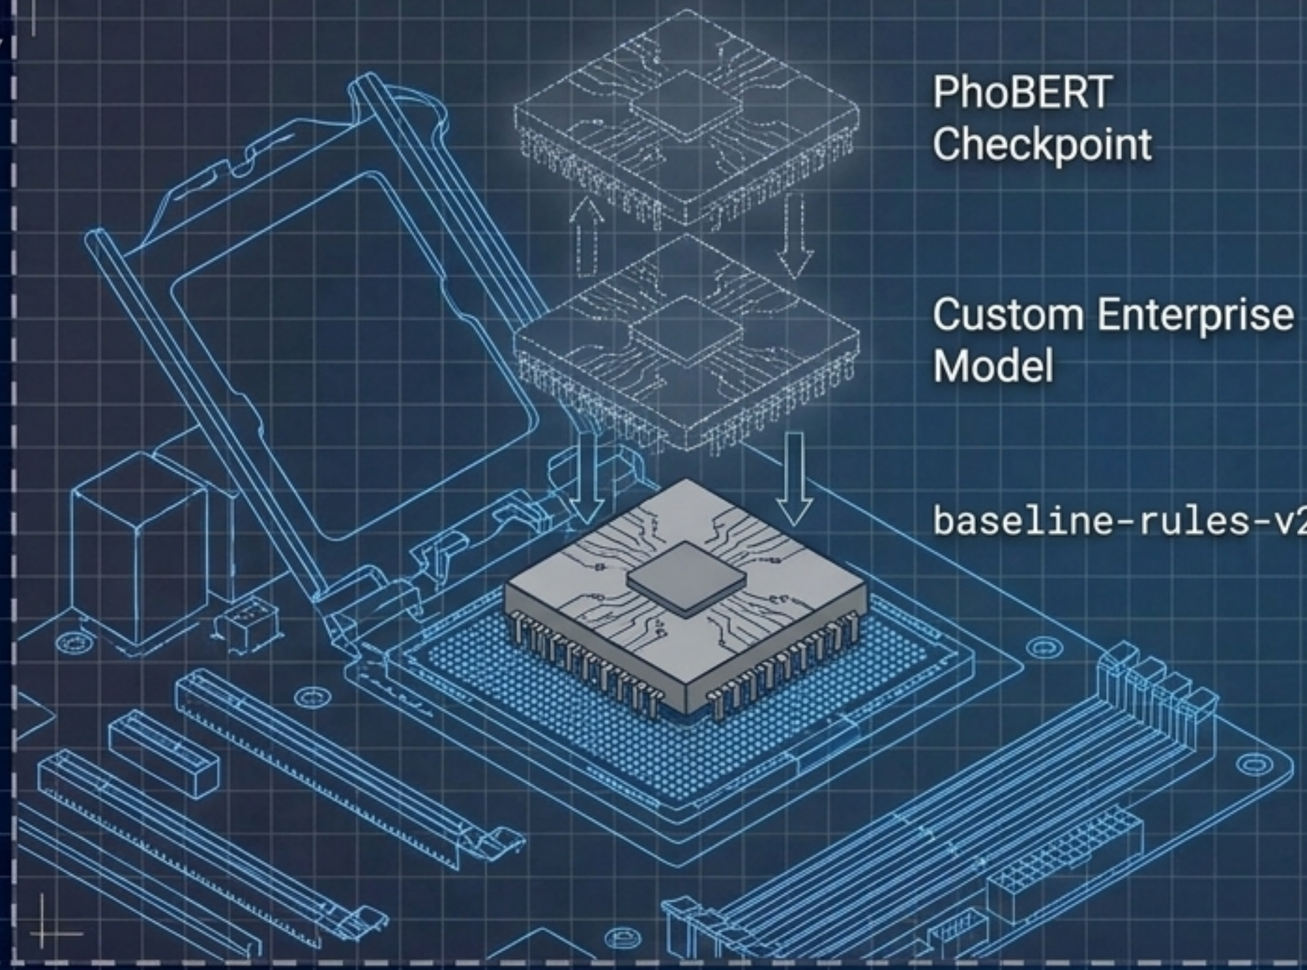

PhoBERT Checkpoint

Custom Enterprise Model

`baseline-rules-v2`

- Thiết kế giao diện yêu cầu đầu ra chuẩn hóa: Label (positive, neutral, negative, unknown), Confidence, Phân bố lớp, Polarity score, và Model Version.
- Bảo vệ API, schema persistence và dashboard khỏi sự thay đổi của thư viện học máy (PyTorch, scikit-learn).
- MVP sử dụng baseline-rules-v2 để chạy sử dụng baseline-rules-v2 để chạy thực thi pipeline toàn vẹn, dọn đường cho việc hoán đổi các Artifact Model an toàn trong tương lai.

DNG NO. ASR-OC-003 | REV 8 | SEALE: NTS

Gemini Notebook

Kiến trúc Event-Driven: PostgreSQL là Nguồn dữ liệu chuẩn (Source of Truth).

Persistence do ứng dụng sở hữu: Dữ liệu được lưu trữ độc lập với nhà cung cấp transcript để áp dụng chính sách quản trị vòng đời riêng.

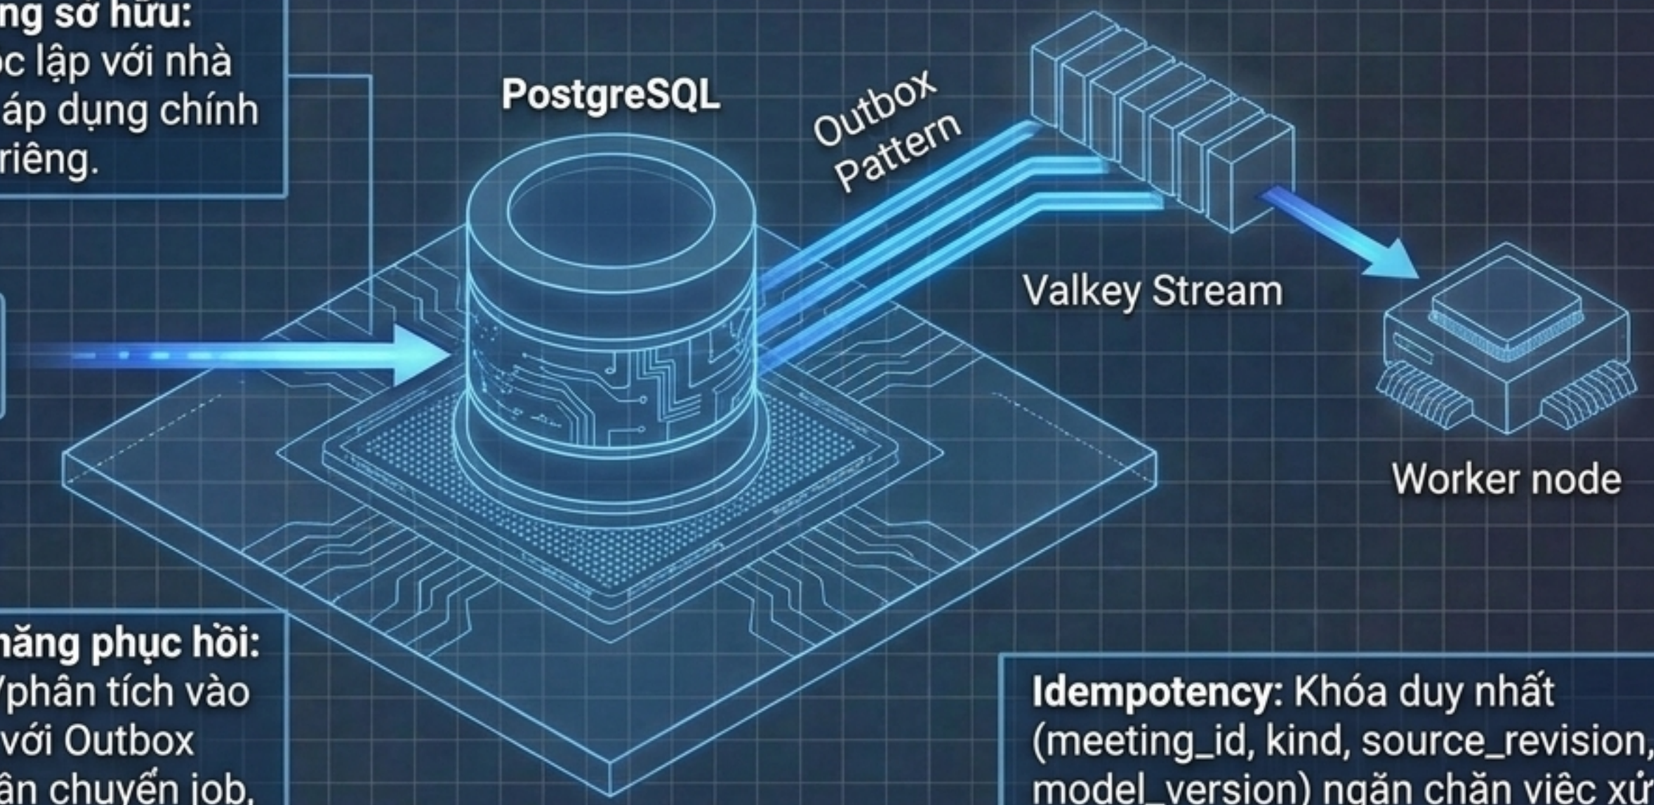

Outbox Pattern & Khả năng phục hồi: Giao dịch ghi segment/phân tích vào DB được commit cùng với Outbox event. Valkey Stream vận chuyển job, nhưng dữ liệu gốc nằm ở DB.

Idempotency: Khóa duy nhất (meeting_id, kind, source_revision, model_version) ngăn chặn việc xử lý lặp khi có retry.

Gemini Notebook

Kiến trúc Evidence: Truy xuất nguồn gốc là một thuộc tính cốt lõi của dữ liệu.

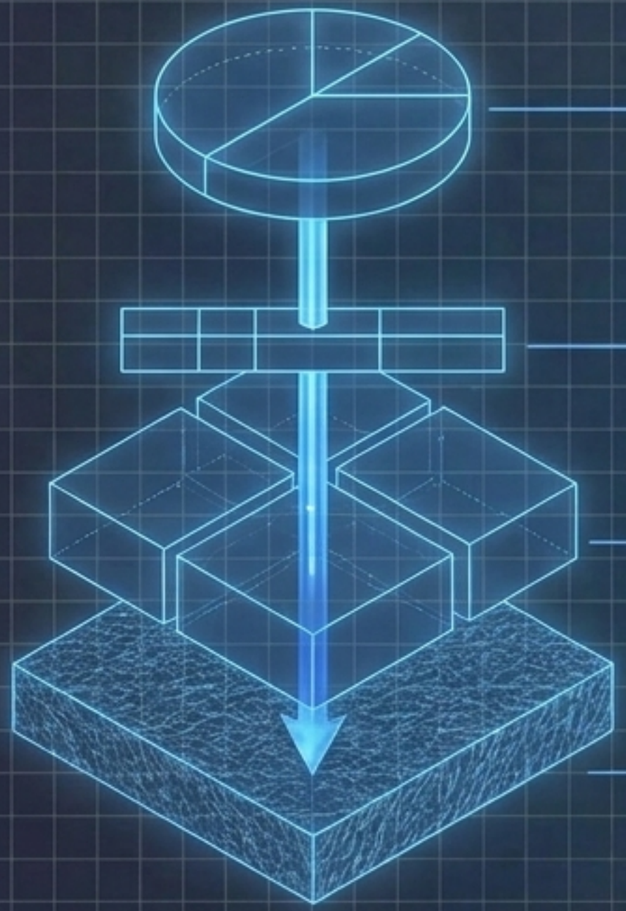

Aggregate Polarity

Prediction
(Label, Confidence)

Analysis Unit
(3 Segments)

Final Segments
+ Source Revision
+ Model Version

- Mỗi kết quả tổng hợp (Aggregate) không phải là một con số vô danh. Nó được liên kết chặt chẽ qua cơ sở dữ liệu.
- Cho phép người dùng đối chiếu kết quả với văn bản gốc, thời điểm, và và phiên bản mô hình/tiền xử lý đã sinh ra nó.
- Cho phép supersede (ghi đè lịch sử có kiểm soát) và rollback khi transcript hoặc mô hình thay đổi.

Gemini Notebook

Giao diện Dashboard: Thiết kế cho sự giám sát của con người (Human Oversight).

Coverage KPI (highlighting missing data)

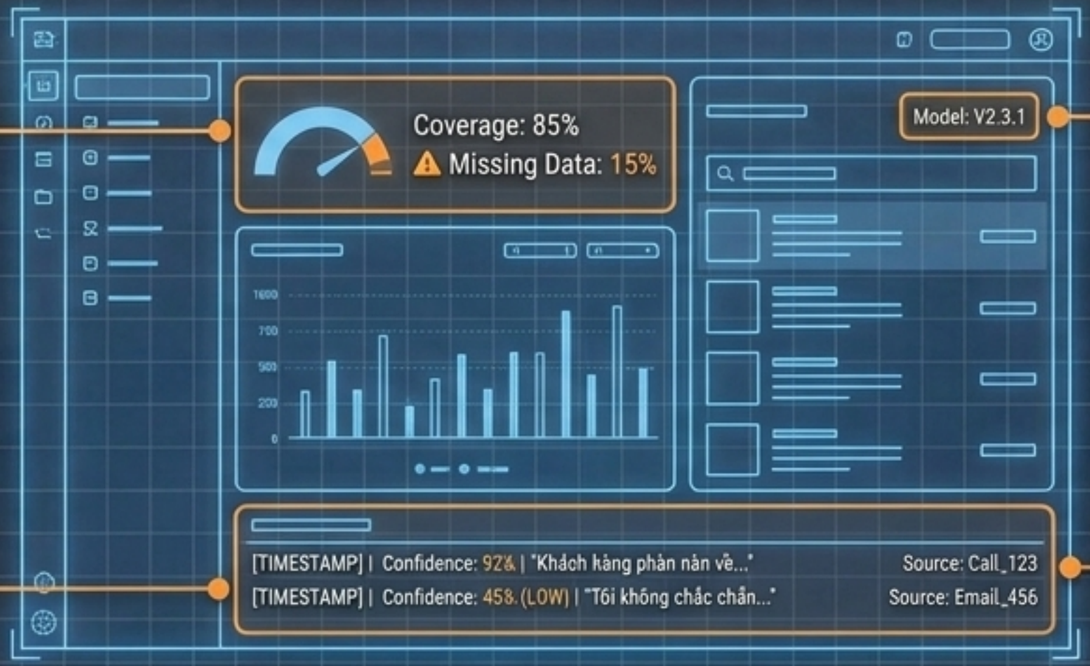

Model Version tag

Coverage KPI aeguimeit staving metric.

The Evidence log panel showing exact quotes and confidence scores.

- Nguyên tắc thiết kế: Context (Ngữ cảnh), Traceability (Khả năng truy vết), Uncertainty (Biểu diễn sự không chắc chắn), và Control (Quyền kiểm soát).
- Trạng thái Unknown, unit bị từ chối, và coverage thấp được hiển thị minh bạch.
- Ngăn chặn việc biến các chỉ số cảm xúc thành công cụ xếp hạng nhân sự hoặc đánh giá mù quáng mà không xem xét văn bản gốc (Evidence).

DNG NO. ASR-OC-005 | REV 8 | SEALE: NTS | DAT

Gemini Notebook

Giao tiếp bất đồng bộ & Delivery cập nhật qua SSE.

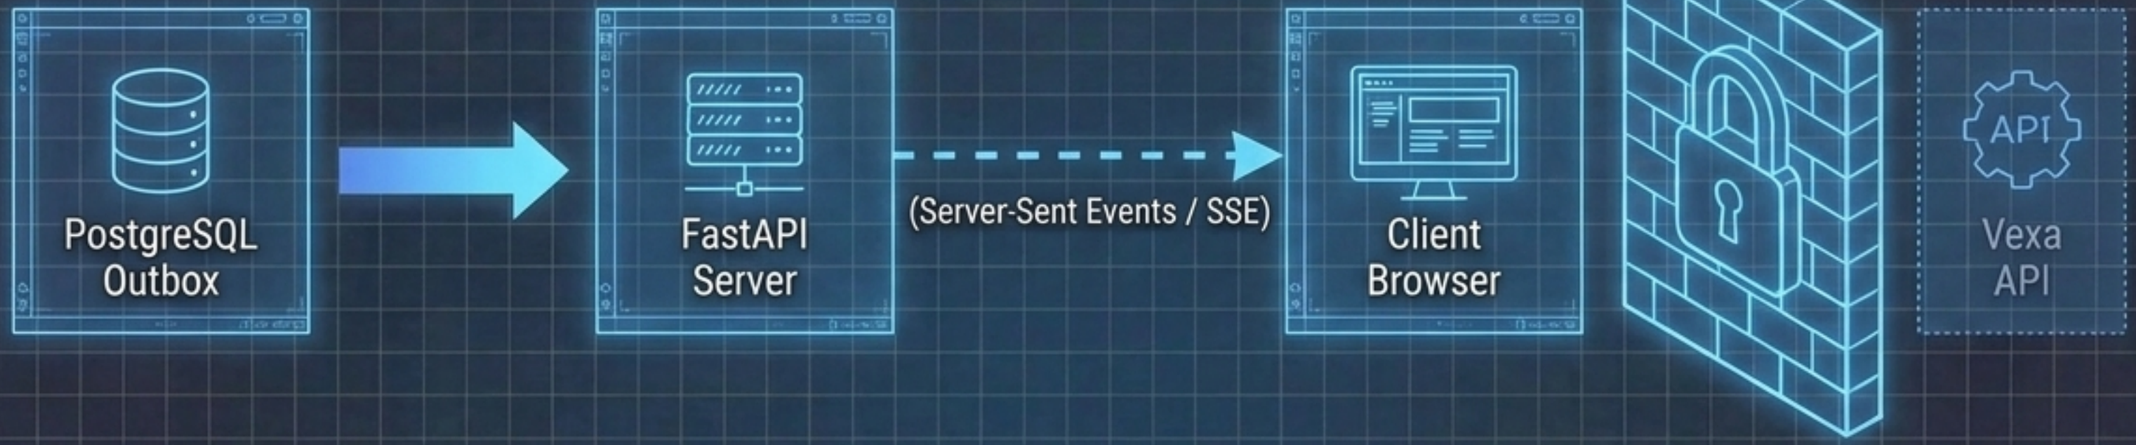

- Endpoint SSE đọc outbox theo meeting, phát sự kiện một chiều (text/event-stream) đến Dashboard.
- Frontend sử dụng debounce timer để làm mới dữ liệu qua API chính thức, đảm bảo tính nhất quán (State-sync) thay vì chỉ tin cậy vào payload của event.
- Bảo mật: Giao diện hoàn toàn cách ly với Vexa API key; không giao tiếp trực tiếp với cơ sở dữ liệu.

DNG NO. ASR-OG-003 REV 8 SEALE: NTS
Gemini Notebook

Hạ tầng Docker: Triển khai độc lập và Ranh giới mạng nghiêm ngặt.

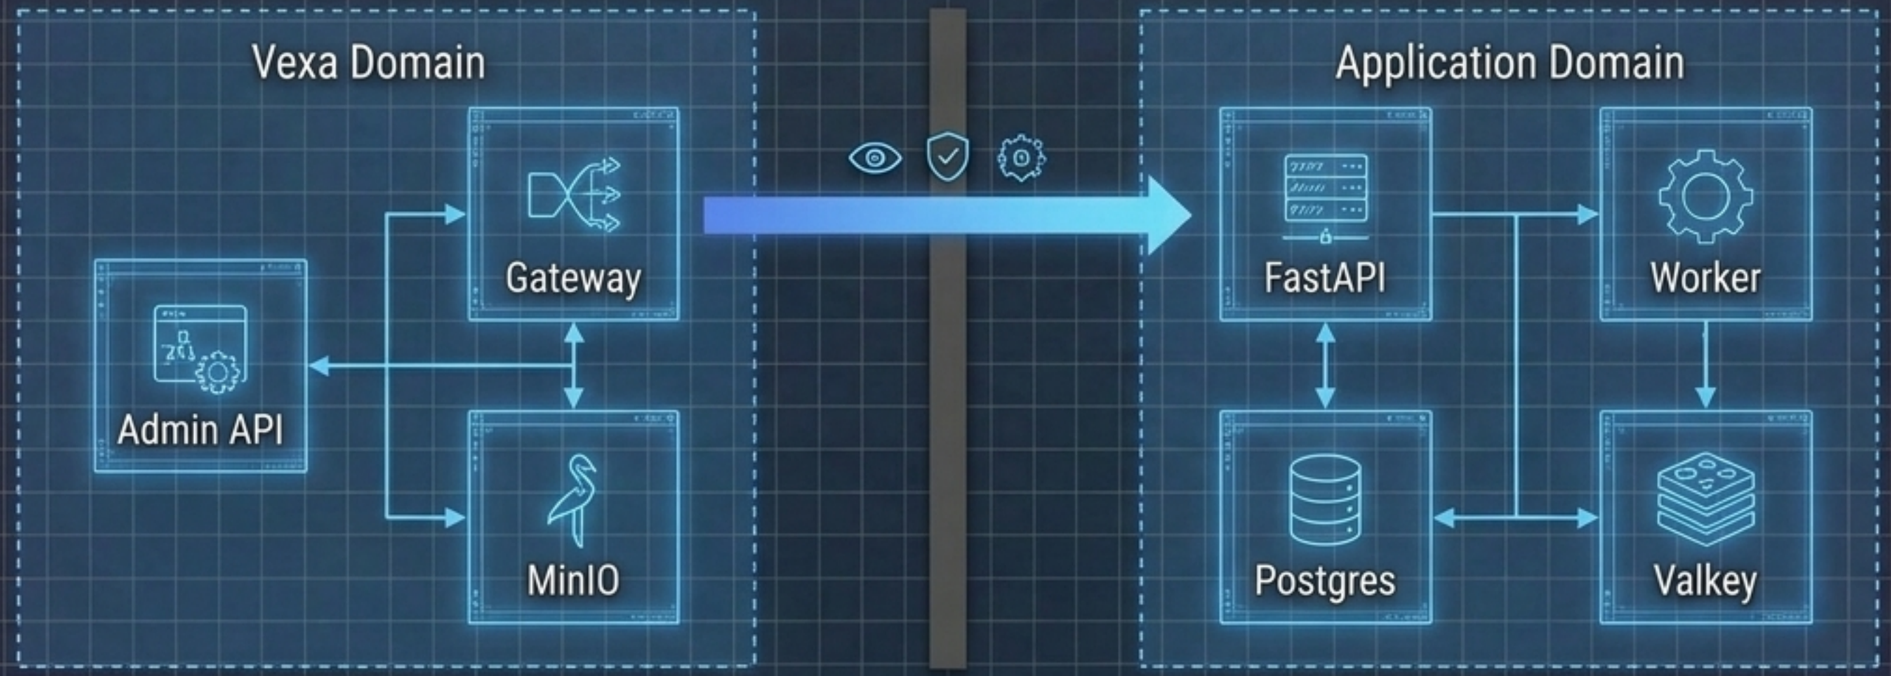

- Hai miền triển khai: Compose Vexa (cung cấp bot/transcript) hoàn toàn tách biệt với Compose Ứng dụng (Meeting Intelligence).
- Tối thiểu hóa bề mặt tấn công: Chỉ API/Dashboard được expose (bind loopback). PostgreSQL, Valkey và Docker socket được giấu kín.
- Sử dụng một cấu hình runtime duy nhất (settings.env) cấp biến cho các container, không lưu trữ trong mã nguồn.

Gemini Notebook

Kiểm chứng Ứng dụng: Xác minh kiến trúc tích hợp.

	11/11 PASSED
[✔]	Unit Tests (Quality Gate, Builder)
[✔]	Service Parser Tests
[✔]	Integration Smoke Pipeline
[✔]	Readiness Checks

Kết quả: 11/11 Pytest passed, bao gồm kiểm thử Unit, Contract và Integration.

Smoke Test Pipeline: Đã xác minh luồng dữ liệu toàn vẹn từ API nhận -> PostgreSQL -> Valkey -> Worker -> Analytics API sử dụng baseline-rules-v2.

Lưu ý khoa học: Đây là kiểm chứng tính đúng đắn của hợp đồng dữ liệu và kiến trúc vận hành, không phải đánh giá độ chính xác (Accuracy/F1) của thuật toán Sentiment.

Gemini Notebook

Quyền Riêng tư từ Thiết kế (Privacy by Design).

Trạng thái bay hơi (Ephemeral State): Message trong Valkey Stream được acknowledge và loại bỏ ngay sau khi xử lý thành công.

Tối thiểu hóa dữ liệu (Data Minimization): Không xử lý hoặc lưu trữ Audio thô trong backend. Chỉ tiếp nhận transcript.

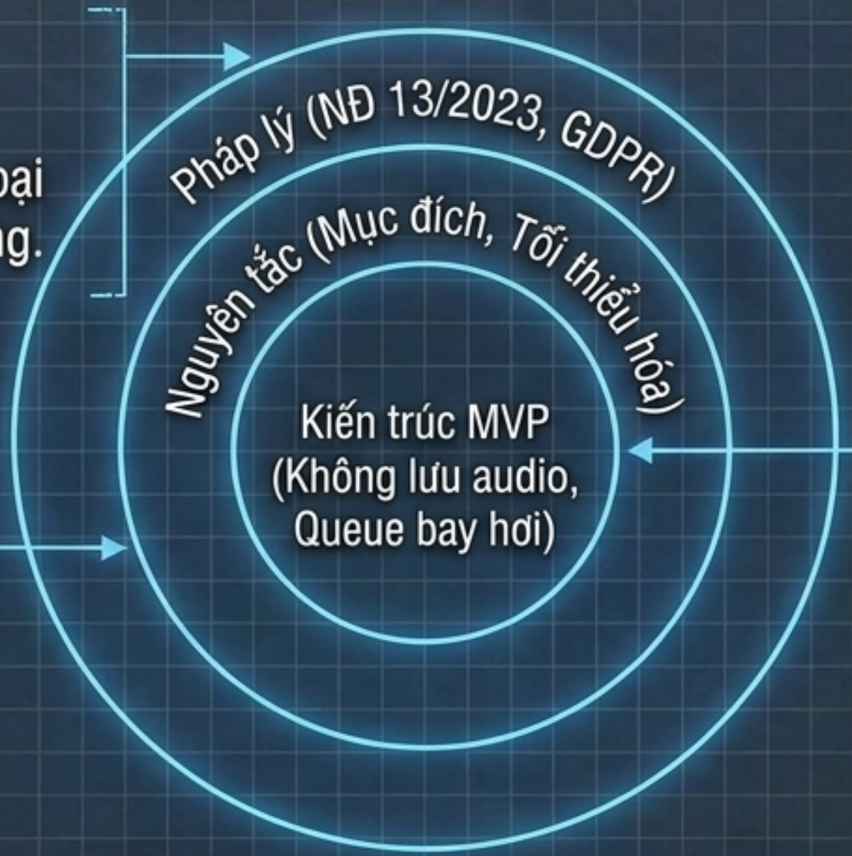

Giới hạn mục đích (Purpose Limitation): Output sentiment chỉ có ý nghĩa trong phạm vi phân tích nội dung cuộc họp, không lập hồ sơ cá nhân, hồ sơ cá nhân.

Triển khai thực tế yêu cầu có Lifecycle Consent rõ ràng trước khi bật bot.

DNC NO. ASR-DG-003 | REV 9 | SEALE: NTS | DATE
Gemini Notebook

Tổng kết Đóng góp Artefact (DSR).

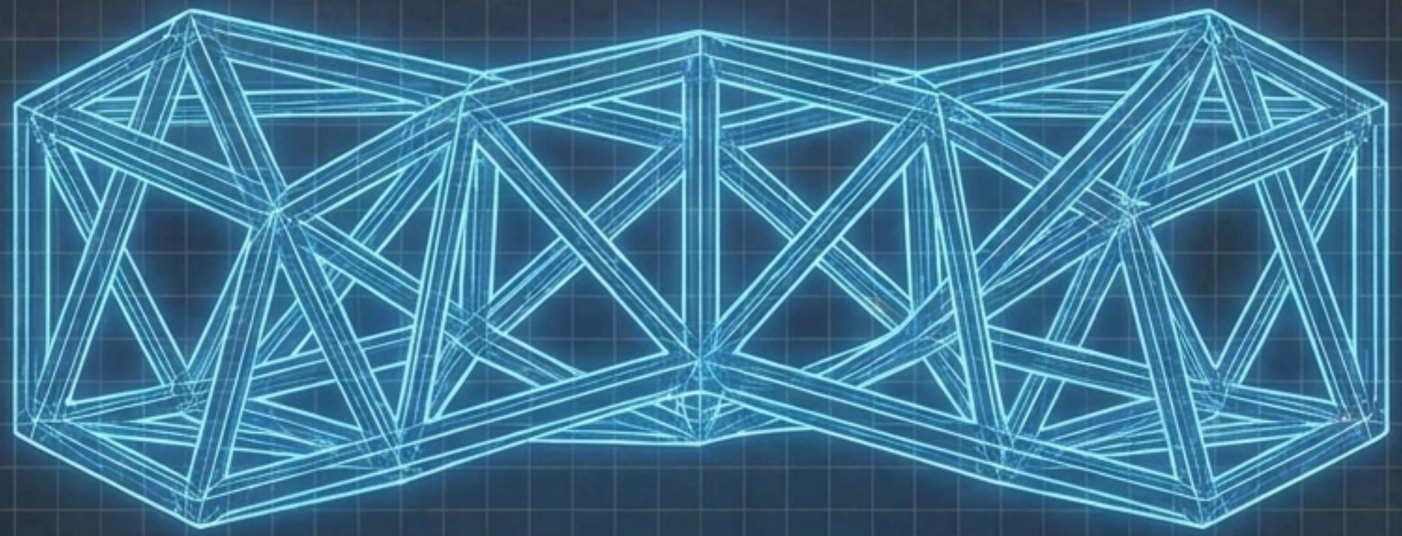

- Khóa luận không chỉ đơn thuần gọi một API học máy. Chúng ta đã kỹ nghệ hóa một Nền tảng hạ tầng có thể kiểm toán.
- MVP giải quyết thành công bài toán tiếp nhận dữ liệu ASR nhiễu, kiểm soát phiên bản linh hoạt, điều phối bất đồng bộ an toàn, và trình bày bằng chứng minh bạch.
- Tạo ra một đường ray an toàn, chuẩn bị sẵn sàng để triển khai các mô hình ngôn ngữ lớn (PhoBERT) vào môi trường họp trực tuyến.

Gemini Notebook

Lộ trình phát triển có thể kiểm chứng.

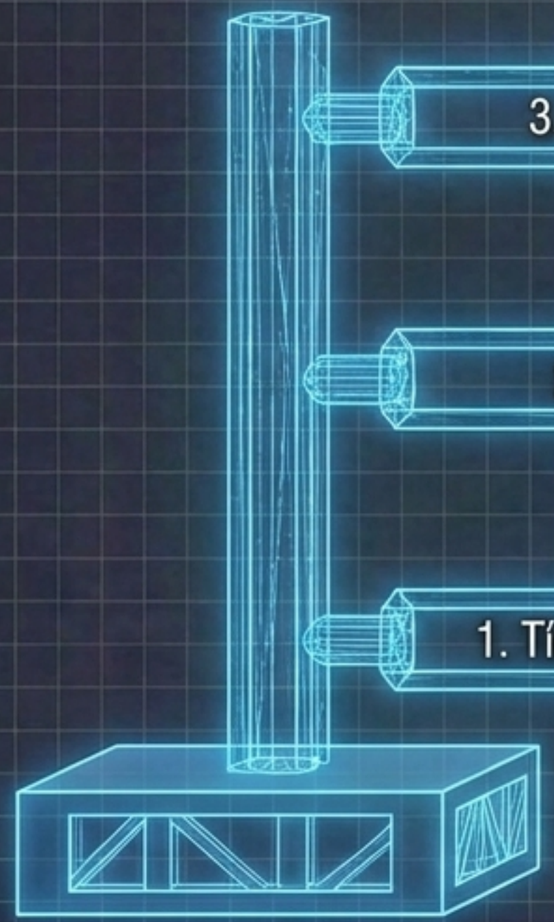

3. Vận hành Production

Triển khai Kubernetes, High Availability Database, thiết lập SLO định lượng, và SSO/RBAC cho quản trị quyền riêng tư thực tế.

2. Mở rộng Nền tảng

Phát triển Platform Adapters chuẩn hóa cho Microsoft Teams, Zoom, và Jitsi.

1. Tích hợp Mô hình (MLOps)

Triển khai MLflow Tracking/Registry, đóng gói Artifact PhoBERT cùng báo cáo Benchmark & Calibration chi tiết.

Current MVP (Google Meet, Local Docker, Baseline)

Gemini Notebook